

Classement des meilleurs modeles IA locaux pour ton PC

Rapport cree le 09/05/2026 pour un Lenovo ThinkPad T14 Gen 2a. But: choisir des modeles rapides, utiles pour coder, pour discuter, et pour analyser des images.

1. Resume simple de ton PC

Element	Valeur	Ce que ca veut dire simplement
PC	Lenovo ThinkPad T14 Gen 2a - 20XLS27604	Bon laptop pro, solide, mais pas une station IA avec grosse carte graphique.
CPU	AMD Ryzen 5 PRO 5650U - 6 coeurs / 12 threads	Correct pour lancer des modeles locaux, mais les gros modeles seront lents.
RAM	40 Go DDR4 2667 MHz	Tres bon point. Tu peux charger des modeles assez gros en RAM.
GPU	AMD Radeon integre - environ 1 Go VRAM dedie	Point faible pour l'IA locale. Pas de grosse VRAM, donc pas de turbo GPU.
Stockage	SSD 512 Go, environ 203 Go libres	Assez pour plusieurs modeles, mais evite de tout installer.
Ollama	0.23.2 deja installe	Parfait, tu peux installer les modeles directement.
Vitesse observee	qwen3:8b autour de 5 tokens/s; gemma3:4b autour de 6 tokens/s	Pour du fluide, vise surtout 2B a 8B.

2. Classement global recommande

Rang	Modele	Taille	Image	Thinking	Vitesse sur ton PC	Qualite	Meilleur usage	Commande
1	qwen2.5-coder:7b	4.7 Go	Non	Non	Rapide	Tres bonne	Coder tous les jours	ollama pull qwen2.5-coder:7b
2	qwen3-vl:4b-thinking	3.3 Go env.	Oui	Oui	Tres rapide	Tres bonne	Images + raisonnement	ollama pull qwen3-vl:4b-thinking
3	gemma3:4b	3.3 Go	Oui	Non	Tres rapide	Bonne	Chat rapide + images simples	deja installe
4	qwen3:8b	5.2 Go	Non	Oui selon mode	Correct	Tres bonne	Assistant general intelligent	deja installe
5	qwen3-vl:2b	1.9 Go	Oui	Possible selon variante	Excellent	Bonne	Image ultra fluide	ollama pull qwen3-vl:2b
6	phi4-mini	2.5 Go	Non	Non	Excellent	Bonne	Assistant leger du quotidien	ollama pull phi4-mini
7	llava-phi3:3.8b	2.9 Go	Oui	Non	Tres rapide	Moyenne+	Images legeres	ollama pull llava-phi3
8	moondream:1.8b	1.7 Go	Oui	Non	Ultra rapide	Simple	Decrire une image vite	ollama pull moondream
9	qwen2.5-coder:14b	9 Go	Non	Non	Moyen	Tres bonne+	Code plus dur	ollama pull qwen2.5-coder:14b
10	deepseek-coder-v2:16b	8.9 Go	Non	Non	Moyen/lent	Tres bonne	Code avance	ollama pull deepseek-coder-v2:16b

3. Meilleurs modeles pour coder

Rang	Modele	Vitesse	Force en code	Pourquoi le choisir	Mon verdict
1	qwen2.5-coder:7b	Rapide	Tres bonne	Le meilleur equilibre sur ton PC: assez fort et pas trop lent.	A installer en premier.
2	qwen2.5-coder:14b	Moyenne	Tres bonne+	Plus fort que le 7B, mais repondra moins vite.	Pour les gros problemes.
3	deepseek-coder-v2:16b	Moyenne/lente	Tres bonne	Bon modele code MoE, mais moins fluide sur CPU.	A tester apres le 7B.
4	qwen3-coder:30b	Lente	Excellente	Tres puissant mais trop gros pour une experience fluide sur ton laptop.	Pas en modele principal.
5	devstral:24b	Lente	Excellente	Tres bon agent code, mais demande trop de puissance pour ton PC.	A eviter si tu veux rapide.

4. Meilleurs modeles image + vision + thinking

Rang	Modele	Image	Thinking	Vitesse	Qualite image	Utilisation ideale
1	qwen3-vl:4b-thinking	Oui	Oui	Tres rapide	Tres bonne	Analyser captures d'ecran, UI, documents, erreurs, schemas.
2	qwen3-vl:2b	Oui	Possible selon variante	Excellent	Bonne	Quand tu veux une reponse tres rapide sur image.
3	gemma3:4b	Oui	Non	Tres rapide	Bonne	Questions simples sur images et chat quotidien.
4	llava-phi3:3.8b	Oui	Non	Tres rapide	Moyenne+	Petit modele vision classique.
5	moondream:1.8b	Oui	Non	Ultra rapide	Simple	Caption rapide: dire ce qu'il y a dans l'image.
6	minicpm-v	Oui	Raisonnement image correct	Moyenne	Tres bonne	Image plus poussee, mais moins fluide.
7	qwen3-vl:8b	Oui	Oui selon variante	Moyenne/lente	Tres bonne+	Plus fort, mais moins agreable sur ton PC.
8	llama3.2-vision:11b	Oui	Non	Lente	Bonne	Pas ideal pour ton PC, surtout sans GPU dedie.

5. A installer maintenant

Priorite	Commande	Pourquoi
1	ollama pull qwen2.5-coder:7b	Ton meilleur modele local pour coder rapidement.
2	ollama pull qwen3-vl:4b-thinking	Ton meilleur modele image + thinking + fluide.
3	ollama pull phi4-mini	Assistant tres leger pour les petites questions.
4	ollama pull moondream	Vision ultra rapide si tu veux juste decrire une image.
5 optionnel	ollama pull qwen2.5-coder:14b	Plus fort en code, mais moins rapide.

6. Modeles a eviter pour ton PC

Modele	Pourquoi eviter
qwen3-vl:30b / 32b	Peut rentrer en RAM, mais trop lent pour ton objectif 'super fluide'.

Modele	Pourquoi eviter
qwen3-vl:235b	Beaucoup trop gros.
llama3.2-vision:90b	Trop lourd pour ton laptop.
llama3.1:70b	Trop lent sans grosse carte graphique.
deepseek-coder-v2:236b	Beaucoup trop gros.

Conclusion simple: installe qwen2.5-coder:7b pour coder, qwen3-vl:4b-thinking pour les images avec raisonnement, et garde gemma3:4b/qwen3:8b que tu as deja pour le quotidien. C'est le meilleur combo rapide pour ton ThinkPad.

Sources principales: Ollama Library pour Qwen2.5-Coder, Qwen3-VL, Gemma 3, Llama 3.2 Vision, MiniCPM-V, Moondream; tests locaux effectues sur ta machine avec Ollama.